

EPL Sentiment Analysis

David João Pinto Ferreira - 2020248052
João Tomás Cardoso Fernandes - 2021219736

1. Introdução

1.1 Contextualização do Cenário Desportivo e Tecnológico

A interseção entre o desporto de alta competição e as tecnologias de processamento de dados (*Big Data*) representa uma das fronteiras mais interessantes da atualidade. A English Premier League (EPL), conhecida como a melhor liga de futebol do mundo, gera não só receitas astronômicas, mas também um enorme volume de dados digitais por ser também a mais mediática. O nosso projeto insere-se neste ambiente ao focar-se na exploração das reações, emoções e opiniões do enorme número de adeptos através da análise de redes sociais, neste caso em particular o Twitter (X atualmente).

Selecionamos, como período temporal para o nosso estudo, a transição entre o final da época 2019/20 e o início da 2020/21. Esta altura tem uma importância histórica particular, pois como sabemos o ano de 2020 foi marcado pela pandemia COVID-19, que forçou a suspensão das competições desportivas e consequentemente os jogos à porta fechada. Neste contexto, todas as redes sociais, com destaque para o Twitter, deixaram de ser apenas canais de "segundo plano" e tornaram-se o único meio acessível aos adeptos para demonstrarem as suas emoções durante o jogo. Com isto, o volume e a intensidade dos dados gerados nesta altura tornaram-se perfeitos para testar várias arquiteturas de *Big Data* e a performance de algoritmos de *sentiment analysis*.

Desenvolvemos este projeto num ambiente virtual (Máquina Virtual (VM) disponibilizada), com isto sofremos algumas restrições e desafios na implementação como a inserção de menos dados do que o previsto inicialmente, por custos computacionais elevados. A solução implementada orquestra um conjunto de ferramentas que foram lecionadas e utilizadas na unidade curricular, Apache Kafka, Apache Spark, PostgreSQL e Grafana, de forma a criar uma pipeline de dados completa, desde a inserção até à visualização analítica proposta.

1.2 Definição do Problema e Objetivos

O problema central que abordamos reside na grande dificuldade de quantificar e qualificar a opinião pública em tempo real quando esta é dispersa por inúmeras micro-interações não estruturadas. As abordagens tradicionais de sondagem ou análise manual são obsoletas face à velocidade e ao volume de dados gerados num só jogo da Premier League.

O objetivo inicial, conforme delineamos na proposta do projeto, era demonstrar como a análise de sentimento dos tweets desportivos pode revelar as emoções, opiniões e a perceção geral do público em relação às equipas da EPL. Para operacionalizar este objetivo, estabelecemos alguns objetivos mais específicos que nos guiaram até ao desenvolvimento

técnico:

1. **Engenharia de Inserção Resiliente:** Implementar um mecanismo capaz de absorver fluxos de dados de alta frequência sem perda de informação, utilizando o Apache Kafka.
2. **Processamento Distribuído em Tempo Real:** Utilizar o Apache Spark para processar, limpar e classificar os dados. O dataset utilizado, proveniente do Kaggle, já inclui uma coluna de *polarity* pré-calculada, o que nos permite focar o processamento na agregação temporal e na correlação de entidades.
3. **Armazenamento Estruturado para Análise Histórica:** Permanecer com os dados processados numa base de dados relacional (PostgreSQL), isto facilita-nos na parte de consultas complexas e na integração com ferramentas de visualização (Grafana).
4. **Visualização e Storytelling dos Dados:** Criar um dashboard no Grafana composto por 4 visualizações distintas que relacionem o impacto dos tweets, volume (quantidade de retweets) e sentimento (polaridade pré calculada), com os eventos reais que nos permite uma leitura intuitiva de tendências e padrões.

Esta arquitetura visa responder a questões fundamentais: Como flutua a lealdade digital dos adeptos ao longo do tempo? O sentimento é impulsionado mais pelos resultados em campo ou pela massa associativa de cada clube? Existe correlação direta entre o volume de discussão e a prestação dos melhores jogadores independentemente da classificação do seu clube?

2. Seleção das Tecnologias para a Pipeline

A nossa seleção tecnológica foi orientada pelos requisitos de escalabilidade e preferência computacional .

- **Apache Kafka:** Escolhemos por ter grande capacidade de *throughput* e baixa latência. O Kafka permite-nos ter múltiplos consumidores com diferentes velocidades de leitura, perfeito para a inserção do processamento analítico.
 - **Apache Spark:** A escolha do Spark sobre o Hadoop é devido à sua capacidade de processamento em memória, que é drasticamente mais rápida para algoritmos iterativos e crucial para calcular a evolução do sentimento ao longo do tempo.
 - **PostgreSQL:** Usamos o PostgreSQL pela sua robustez relacional e capacidade de lidar com *time series* através de otimizações de indexação, e por termos experiência com o mesmo noutras unidades curriculares anteriores, serve perfeitamente como *serving layer* para o Grafana.
 - **Grafana:** A preferência pelo Grafana baseia-se na sua leveza e integração nativa com fontes de dados de séries temporais, e pelo mesmo motivo de experiência do PostgreSQL, permite a atualização dinâmica dos dashboards em curtos intervalos de tempo.
-

3. Arquitetura do Sistema e Implementação Técnica

3.1 Como funciona a nossa pipeline de dados?

O fluxo começa com a inserção de dados brutos, passa por um canal de mensagens, sofre várias transformações num mecanismo de processamento distribuído, é armazenado numa base de dados estruturada e, por fim, é utilizado pela camada de visualização.

Componente	Função	Tecnologia
Fonte dos dados	Origem dos dados brutos (CSV)	Dataset do Kaggle
inserção	Message Broker	Apache Kafka
Processamento	ETL, Agregação e Cálculos	Apache Spark
Armazenamento	Persistência Relacional	PostgreSQL
Visualização	Dashboarding e Analytics	Grafana

3.2 Fase de inserção: Apache Kafka

Esta fase é responsável por ler o dataset "2020-07-09 till 2020-09-19.csv" e disponibilizá-lo para o sistema. O dataset, cobre o período de 09 de julho a 19 de setembro de 2020, contém colunas como o texto do tweet, o nome da equipa mencionada, a polaridade (positiva, negativa ou neutra, valores de -1 a 1), o número de retweets, nome do utilizador, localização do utilizador, entre outros.

Na VM, configuramos um cluster Kafka (single-node) gerido pelo Zookeeper. Foi desenvolvido um *Producer* em Python que lê o ficheiro CSV linha a linha e publica as mensagens num tópico dedicado, denominado por "epl_tweets".

- **Serialization:** As mensagens foram serializadas em formato JSON para garantir a preservação da estrutura dos dados e facilitar a *deserialization* pelo Spark.
- **Partitioning:** Configuramos o tópico com uma partição devido ao facto da obtenção dos dados provirem do mesmo dataset, obtendo a vantagem do envio dos dados ser efetuada de forma cronológica, sem assincronias.

3.3 Camada de Processamento: Apache Spark

Submetemos um job de **Spark Structured Streaming** que subscreve o tópico "epl_tweets"

do Kafka para processamento em micro-batches.

Transformações e Lógica:

1. **Ingestão e Parsing:** O Spark é o *Consumer* que aplica um esquema estrito (*StructType*), extrai features chave como *group_name* (equipa), *polarity* e *retweet_count*.
2. **Processamento via *foreachBatch*:** Ao contrário de agregações nativas, optamos pelo processamento de cada micro-batch através de uma função personalizada no *driver*. Isto permite-nos implementar uma lógica complexa de interações diretas com a base de dados relacional.
3. **Validação e Limpeza:** A Implementação de filtros de qualidade ("Sanity Check") para descartar anomalias, ignorar tweets com polaridade absoluta superior a 2.0 ou contagens de retweets excessivas (>13.000), que indicariam spam, erros de recolha, alguns outliers e também para melhorar a visualização (ao diminuir a existência de impacto no tweet exageradissima).
4. **Cálculo de Impacto Ponderado:** Em vez de analisar apenas a frequência, implementamos uma métrica específica, o impacto real do tweet na reputação da equipa. Esta métrica deriva da multiplicação da polaridade pelo alcance do tweet(retweet's):

$$\text{Impacto} = \text{Polaridade} \times \max(1, \text{Retweets})$$

Isto assegura que tweets virais tenham um peso proporcionalmente maior na análise de sentimento do que tweets isolados.

Gestão de Estado e Acumulação: Implementamos no nosso sistema dicionários globais para acumular o sentimento total e a contagem de tweets por equipa ao longo da execução do stream, persistindo o estado acumulado continuamente.

Enriquecimento com Dados Estáticos: O processamento cruza os dados de streaming com as tabelas de domínio estáticas (posicionamento na liga, top scorers e assistências). Isto permite que, ao detetar um tweet sobre o "Liverpool FC", o sistema associa automaticamente métricas de jogadores como "Mohamed Salah" e a posição atual da equipa na tabela, enriquece a informação gravada no PostgreSQL (*team_sentiment* e *player_stats*) e consequentemente as nossas visualizações.

3.4 Camada de Armazenamento: PostgreSQL

A persistência dos dados é assegurada por uma instância PostgreSQL local, configurada para aceitar conexões autenticadas via *scram-sha-256*. A escrita é realizada diretamente pelo consumidor Spark através do driver *psycopg2*, utilizando um utilizador dedicado (*spark_user*) com permissões granulares no esquema público.

Foi desenhado um esquema relacional composto por três tabelas, estruturadas para alimentar diferentes painéis do Grafana:

- **tweet_counts:** Armazena o volume de dados, registando o contador instantâneo do *batch* e o total acumulado (*total_count*) por equipa e carimbo temporal.
- **team_sentiment:** Foca-se na qualidade da interação, persistindo o *sentiment_impact* (ponderado por retweets) e a posição atual da equipa na liga (*position*), permitindo correlações entre desempenho desportivo e reputação online.
- **player_stats:** Uma tabela de factos que associa métricas estáticas de jogadores (Golos/Assistências) ao impacto sentimental da equipa no momento da análise, contendo colunas como *metric_type* e *metric_number*

Esta camada atua como o *Single Source of Truth* para a camada de visualização, garantindo que os dados voláteis do streaming sejam estruturados de forma tabular e persistente para consulta histórica.

3.5 Camada de Visualização: Grafana

A camada final é o dashboard interativo. O Grafana conecta-se ao PostgreSQL e executa queries SQL dinâmicas. Foram criadas 4 visualizações específicas que exploram diferentes dimensões dos dados.¹

4. Análise de Dados e Insights do Dashboard

Esta seção detalha a interpretação analítica das 4 visualizações implementadas no painel Grafana. O dashboard funciona num ambiente de *streaming* de dados, atualiza a cada 5 segundos, o que permite uma monitorização em "quase tempo-real" do movimento.

4.1 Visualização 1: Evolução Dinâmica da Polaridade (Time Series)


Descrição Técnica: Um gráfico de linhas (Time Series) que ilustra a evolução temporal do "Impacto de Polaridade" acumulada. O eixo do tempo avança em intervalos de receção contínua (streaming).

- **Métrica:** A linha representa a evolução do impacto dos tweets por equipa ao longo do tempo de injeção na database.
- **Legenda:** Cada cor corresponde a um clube, identificado também pela sua posição

final na tabela da EPL (ex: 6º Tottenham, 4º Chelsea).

Análise e Insights: Esta *time series* revela a esperada rivalidade do futebol inglês.

- **O início do sentimento:** Notamos que o sentimento não cresce de forma linear para todos. O **Tottenham Hotspur (linha vermelha)** destaca-se com uma ascensão vertical abrupta, distanciando-se significativamente dos rivais. Isto poderia indicar a existência de um evento ou tópico de grande alcance (muitos retweets em tweets positivos) que impulsionou o impacto da marca num curto espaço de tempo.
- **Consistência vs. Alcance:** Enquanto clubes como o **Chelsea (linha amarela)** e o **Man. United (linha roxa)** mostram um crescimento gradual e consistente, o pico do Tottenham demonstra que, nas redes sociais, o "impacto" é muitas vezes ditado por picos de intensidade (eventuais polémicas, golos ou notícias de última hora) e não apenas pela presença constante.



4.2 Visualização 2: Ranking de Impacto vs. Posição na Liga

Descrição Técnica: Um gráfico de barras horizontais (Bar Gauge) que compara o valor acumulado do "Impacto de Sentimento" de cada equipa com a sua classificação final na liga (EPL Position).



Análise e Insights: A visualização desmonta a correlação direta entre a tabela classificativa e a relevância digital:


- Ao contrário do que a classificação desportiva indicaria, o **Manchester United** (3º lugar) e o **Arsenal** (8º lugar) são os líderes indiscutíveis de impacto, com **355.984** e **342.545** pontos, respetivamente.
- **O Fenómeno do Arsenal (8º Lugar):** O Arsenal é o caso de estudo mais interessante: apesar de uma época desportiva medíocre (8º lugar), gerou quase **o dobro do impacto do Liverpool** (1º lugar/Campeão, com 184.794). Isto prova que a base de adeptos online e a "cultura de meme/crítica" geram mais tração do que a vitória tranquila.
- **Crise de Reputação (O Caso Crystal Palace):** O gráfico revela uma anomalia severa para o **Crystal Palace**, que apresenta um impacto negativo massivo de **-312.684**. Isto indica que, durante a janela de análise, o clube esteve envolvido numa controvérsia que gerou uma onda de sentimento tóxico ou reação adversa, anulando qualquer métrica positiva.

Interpretação: O "campeão das redes sociais" raramente é o campeão da liga. Clubes com grandes massas associativas globais (Man Utd, Arsenal) geram ruído independentemente da sua forma atual, enquanto o sucesso desportivo do Liverpool não se traduziu proporcionalmente em domínio da conversação.

4.3 Visualização 3: Performance Individual vs. Impacto do Clube (Scatter Plot)

Descrição Técnica: Um gráfico de dispersão (*Scatter Plot*) que cruza dados de performance individual com o impacto mediático do clube.

- **Bolas Verdes:** Top 5 Melhores Marcadores da liga (Eixo X = Nº de Golos; Eixo Y = Impacto do Clube).
- **Bolas Amarelas:** Top 5 Melhores Assistentes da liga (Eixo X = Nº de Assistências; Eixo Y = Impacto do Clube).



Análise e Insights: A visualização revela uma **não-linearidade** entre sucesso desportivo e sucesso mediático.


- **O "Outlier" de Impacto:** Destaca-se um ponto verde isolado no topo superior direito (aprox. **345k de impacto** com 22 golos). Isto indica um jogador que, além da performance de elite, joga num clube com uma base de adeptos massiva que amplifica cada ação.
- **A Disparidade Vertical:** Ao observar a marca dos **22 golos** no eixo X, vemos a prova definitiva da influência do clube. Temos um jogador com quase 350k de impacto e outro, com exatamente o mesmo número de golos, com **menos de 10k de impacto** (bola verde junto à base do gráfico).

Interpretação: O gráfico confirma que a "camisola pesa" nas redes sociais. Jogadores com estatísticas idênticas (ex: 22-23 golos) têm destinos digitais opostos dependendo do clube que representam. Enquanto o jogador de um "Big 6" vê a sua performance amplificada para

níveis estratosféricos (o ponto de 345k), o jogador de um clube médio (como Southampton ou Leicester), mesmo sendo um dos melhores marcadores, atinge um máximo baixo de visibilidade, permanecendo frequentemente abaixo dos 100k de impacto. O contexto do clube atua, portanto, como um multiplicador (ou limitador) da fama individual.

4.4 Visualização 4: Quota de Discussão (Donut Chart)

Descrição Técnica: Um gráfico circular (Donut Chart) que contabiliza o volume bruto de tweets (*count*) associados a cada clube no período analisado, permitindo uma visualização rápida da fatia de "ruído" gerada por cada equipa.



Análise e Insights: A distribuição de volume revela uma liderança surpreendente e expressiva:

- **Líder em Volume:** O **Leicester City FC** (fatia Vermelha) domina a discussão com **6832 tweets**, representando isoladamente uma grande percentagem do total.
- **Seguidores:** O Chelsea FC aparece em segundo lugar com **4367 tweets**, seguido pelo Burnley FC (3536).
- **A surpresa dos "Gigantes":** Clubes tradicionalmente mediáticos aparecem com volumes comparativamente baixos neste lote de dados. O Manchester City (2108), Manchester United (1861) e Liverpool (2450) têm volumes de tweets significativamente inferiores ao líder.

Interpretação do Volume vs. Impacto: Ao cruzar estes dados com a análise de Impacto, a conclusão "Quantidade $\neq$ Qualidade" torna-se ainda mais evidente:

- **Eficiência de Engajamento:** Embora o Leicester City tenha quase **3 vezes mais**

tweets que o Tottenham Hotspur (6832 vs 2264), o Tottenham lidera em métricas de impacto (como visto nos gráficos anteriores). Isto sugere que a discussão sobre o Leicester é volumosa mas dispersa (muitos tweets sem interação), enquanto a do Tottenham é "viral" (menos tweets, mas com alto número de retweets).

5. Discussão Crítica e Desafios de Implementação

5.1 Avaliação da Infraestrutura (VM e Escalabilidade)

A execução do projeto na VM disponibilizada impôs restrições de memória e CPU que obrigaram a otimizações.

- **Gestão de Recursos:** O Spark, por defeito, tenta ocupar toda a memória disponível. Foi necessário configurar cuidadosamente os parâmetros `spark.executor.memory` e `spark.driver.memory` para evitar que o processo fosse morto pelo sistema operativo (OOM Kill), garantindo que o Kafka e o Postgres pudessem coexistir na mesma máquina.
- **Latência:** Apesar de estar numa única VM, a latência *end-to-end* (desde a inserção no Kafka até à visualização no Grafana) manteve-se na ordem dos segundos, validando a eficiência da stack tecnológica.
- **Escalabilidade Teórica:** Se este sistema fosse migrado para a cloud (AWS ou Azure) para monitorizar todas as ligas mundiais, a arquitectura manter-se-ia. O Kafka escalaria horizontalmente adicionando *brokers*, e o Spark adicionando *workers*. O PostgreSQL, eventualmente, poderia ser substituído por um *Data Warehouse* (Snowflake) ou uma base de dados *Time-Series* nativa (TimescaleDB).

5.2 O Valor para um Possível Negócio

Além do exercício académico, este relatório demonstra um valor analítico tangível. Podendo ser utilizar de diversas formas por clubes, tais como:

1. Medir a aceitação imediata de uma nova contratação ou equipamento.
2. Detectar focos de insatisfação antes que se tornem protestos organizados.
3. Ajustar estratégias de comunicação em tempo real durante os jogos.

6. Conclusão e Recomendações Futuras

Este projeto demonstra a viabilidade e o valor estratégico de uma arquitetura Big Data integrada para monitorização em tempo real do sentimento público em plataformas digitais, especificamente aplicada à análise de dados do Twitter durante uma parte da temporada 19/20 da English Premier League. A solução implementada com Kafka, Spark, PostgreSQL e Grafana

prova ser eficiente, resiliente e capaz de gerar insights analíticos complexos que desafiam as percepções tradicionais sobre a relação entre sucesso desportivo e visibilidade digital.

6.1 Contribuições Técnicas e Científicas

A arquitetura proposta oferece três contribuições principais ao campo da análise de dados desportivos. Primeira, a implementação de um pipeline escalável que integra ingestão assíncrona (Kafka), processamento distribuído (Spark) e armazenamento persistente (PostgreSQL). Segunda, a métrica de "impacto ponderado", que multiplica polaridade pelo alcance de retweets, supera abordagens simplistas de contagem de frequência, captando a verdadeira dinâmica de amplificação nas redes sociais. Terceira, a correlação entre performance individual de atletas, posicionamento do clube e visibilidade digital revela que o contexto organizacional é determinante na amplificação de narrativas individuais.

6.2 Descobertas Críticas

A análise dos dashboards do Grafana revelou dois paradoxos fundamentais. O primeiro contradiz a hipótese intuitiva de que campeões geram maior impacto digital, o Manchester United, classificado em 3º lugar, liderou o ranking de impacto, quadriplicando o Manchester City (2º lugar). O Liverpool, campeão da temporada, não se posicionou no topo do gráfico de impacto, sugerindo que a consistência desportiva não se traduz automaticamente em amplificação mediática. O segundo paradoxo evidencia a desconexão entre volume e impacto, o Leicester City gerou o maior volume de tweets, mas com alcance significativamente inferior ao Manchester United, demonstrando que a quantidade de interações não correlaciona com qualidade de alcance.

Além do exercício técnico, o projeto articula casos de utilização práticos com valor tangível para clubes profissionais, a detecção precoce de insatisfação comunitária antes de materializar em protestos organizados, medição em tempo real da aceitação de contratações, e ajuste dinâmico de estratégias de comunicação durante os períodos de jogo.

6.3 Conclusão Final

Este projeto demonstra como a intersecção entre desporto, redes sociais e análise quantitativa pode revelar estruturas ocultas de opinião pública. A capacidade de quantificar e qualificar em tempo real as emoções dispersas de diversos adeptos representa uma fronteira genuína na compreensão de dinâmicas comunitárias digitais, com implicações que extrapolam significativamente o contexto específico do futebol inglês.