

Exploring Explainable Neural Networks for Spotify Music System Recommendation

David Ferreira¹, João Tomás², Diogo Almeida³,

¹2020248052, ²2021219036, ³2024140200,
uc2020248052@student.uc.pt, uc2021219036@student.uc.pt, –

Abstract

A música desempenha um papel crucial na nossa vida diária, sendo uma fonte constante de conforto e inspiração. No mundo digital, as plataformas de streaming, como o Spotify, enfrentam o desafio de gerir quantidades de dados de users muito volumosas, tornando essencial a utilização de algoritmos eficazes para recomendações personalizadas. O uso de redes neuronais pode ser usado na criação de sistemas de recomendação de músicas baseado em atributos de datasets das plataformas de streaming.

1 Introdução

Os sistemas de recomendação tornaram-se uma área de investigação importante desde o aparecimento dos primeiros artigos sobre filtragem colaborativa em meados dos anos 90. [1]

São, agora, parte integrante do panorama digital, especialmente nas plataformas de comércio eletrónico e de conteúdos. Estes sistemas são concebidos para sugerir itens aos utilizadores com base em vários algoritmos que analisam as preferências e os comportamentos dos utilizadores. A eficácia destes sistemas é crucial para melhorar a experiência do utilizador e promover o seu envolvimento, especialmente em ambientes dinâmicos como os serviços de streaming de música. [2]

No contexto deste trabalho, exploramos os atributos musicais presentes numa junção de dois datasets, utilizando técnicas de visualização para investigar as suas distribuições e relações. Esta análise inicial é essencial para entender como os dados são distribuídos, identificar possíveis correlações entre variáveis e preparar o terreno para a construção de modelos preditivos ou sistemas de recomendação.

Os comportamentos passados do utilizador, como o que ele habitualmente vê ou ouve, são informação crucial, pois o sistema aprende consoante as preferências ao longo do tempo para sugerir novos conteúdos que sejam semelhantes. [3]

Apesar de todos estes avanços, a atual geração de sistemas de recomendação ainda necessita de mais melhorias para tornar os métodos de recomendação mais eficazes e aplicáveis a uma gama ainda mais vasta de aplicações reais. [1]

A avaliação da eficácia dos sistemas de recomendação coloca vários desafios. Os métodos tradicionais centram-se frequentemente na precisão da previsão - como as recomendações do sistema se alinham com as preferências conhecidas do utilizador. No entanto, num ambiente dinâmico como o Spotify, onde os gostos dos utilizadores podem evoluir rapidamente, também é importante considerar a satisfação e o envolvimento do utilizador. Equilibrar a precisão com a diversidade nas recomendações é crucial; os utilizadores podem preferir uma mistura de faixas familiares e novas para manter a sua experiência de audição fresca. [2]

Este estudo fornece insights valiosos para a compreensão dos dados e estabelece uma base sólida para aplicações futuras, como a criação de sistemas de recomendação personalizados e previsões baseadas em características musicais.

2 Motivação

A personalização é um elemento-chave no sucesso de plataformas de streaming, onde users frequentemente interagem com grandes volumes de conteúdo. Sistemas de recomendação eficientes podem não apenas aumentar o engajamento do user, mas também criar novas oportunidades de descoberta musical. As redes neuronais oferecem uma abordagem promissora, permitindo a modelagem de interações complexas e melhorando a qualidade das recomendações.

O trabalho é particularmente relevante em um contexto onde os métodos tradicionais, como filtros colaborativos simples, mostram limitações em lidar com a dimensionalidade dos dados e a diversidade de preferências dos users. Este projeto busca superar essas limitações e avançar no estado da arte dos sistemas de recomendação.

3 Descrição dos Dados e Visualizações

Descrição dos Dados

O conjunto de dados utilizado no estudo é composto por interações entre users e músicas disponíveis no Spotify, incluindo informações relevantes para a tarefa de recomendação (Figure 1). As principais características do conjunto de dados são:

- users:** IDs representando os diferentes users.
- Músicas:** IDs únicos para cada música no catálogo.
- Atributos das Músicas:** Incluem informações como:

- Género musical
- Popularidade
- Dançabilidade (*danceability*)
- Energia (*energy*)
- Acústica (*acousticness*)
- Valência (*valence*)
- Tempo (*tempo*)

- **Interações:** Notas ou avaliações dos users para as músicas.

O conjunto de dados foi dividido em treino (70%) e validação (30%), garantindo que as interações entre users e músicas fossem distribuídas de forma representativa.




Figure 1: Distribuição de interações por user. A maioria dos users avaliou poucas músicas.

Análise Exploratória de Dados (EDA)

Uma análise exploratória inicial foi conduzida para entender a distribuição dos dados e identificar padrões relevantes. Os seguintes insights foram obtidos:

- A maioria dos users interagiu com menos de 20 músicas, mas existem alguns users que avaliaram centenas de músicas, indicando um comportamento de *long-tail*.
- As músicas mais populares foram avaliadas por um grande número de users, enquanto a maioria das músicas teve poucas interações.
- Os atributos musicais apresentaram distribuições esperadas, como:
 - *Danceability* variando entre 0.2 e 0.9, com média em torno de 0.6.
 - *Energy* com maior concentração entre 0.5 e 0.8.
 - *Valence* com tendência próxima a 0.5 (neutra).

Divisão Treino-Validação

Para treinar os modelos de recomendação, o conjunto de dados foi dividido com base em um esquema temporal, preservando a ordem cronológica das interações. Essa abordagem simula um cenário real, onde previsões devem ser feitas para interações futuras.

4 Dataset: Songs

Visão Geral

O *Dataset-Songs* representa o alicerce do algoritmo de recomendação, encapsulando metadados detalhados sobre as faixas disponíveis no Spotify. Este conjunto de dados serve como repositório de informações utilizadas tanto para sistemas de recomendação colaborativos quanto baseados em

conteúdo. Ao explorar estas características, o modelo pode identificar padrões e criar sugestões personalizadas para os utilizadores.

Características

Os principais atributos incluídos no conjunto de dados de músicas são:

- ****ID da Música**:** Identificador único para cada música no catálogo do Spotify.
- ****Metadados da Faixa**:**
 - **Nome:** O título da música.
 - **Artista(s):** Nome(s) do(s) artista(s) associado(s) à música.
 - **Álbum:** O álbum em que a música está presente.
 - **Ano de Lançamento:** O ano em que a música foi lançada.
- ****Características Áudio**:**
 - **Danceabilidade:** Mede a adequação da música para dançar, variando entre 0 e 1.
 - **Energia:** Representa o nível de intensidade e atividade da música.
 - **Acústica:** Estima a probabilidade de a música ser acústica.
 - **Valência:** Descreve a positividade emocional transmitida pela música.
 - **Tempo:** A velocidade da música, medida em batidas por minuto (BPM).
- ****Popularidade**:** Um valor numérico que indica a popularidade da música no Spotify, com base em interações recentes dos utilizadores. a Figura 2 mostra a distribuição das músicas por popularidade (0 - 100) no dataset utilizado.
- ****Gêneros**:** Na Figura 3, pode-se visualizar a organização das músicas por género. No entanto, estes valores ainda apresentam outliers, pelo que se procedeu à normalização dos mesmos, como se pode verificar na Figura 4.




Figure 2: Distribuição do número de músicas por popularidade.




Figure 3: Distribuição do número de músicas por género.




Figure 4: Distribuição do número de músicas por género (normalizado).

Propósito e Utilização

Este conjunto de dados é utilizado para:

- Capturar as características das músicas para permitir recomendações personalizadas.
- Facilitar o filtro baseado em conteúdo, ligando as preferências dos utilizadores a atributos específicos das músicas.
- Aumentar os modelos híbridos, fornecendo metadados ricos para decisões complexas.

Pré-processamento

O pré-processamento incluiu:

- Normalização de características numéricas (e.g., danceabilidade, energia) para o intervalo $[0,1]$.
- Codificação *one-hot* de características categóricas, como géneros.
- Tratamento de valores em falta, imputando a mediana para campos numéricos e a moda para os categóricos.

5 Dataset: Users

Visão Geral

O *Dataset-Users* encapsula o histórico de interações e as preferências dos utilizadores do Spotify. Este fornece entradas cruciais para os modelos de filtro colaborativo, refletindo o comportamento dos utilizadores através de classificações e padrões de escuta.

Características

O conjunto de dados inclui os seguintes atributos:

- ****ID do Utilizador****: Identificador único para cada utilizador do Spotify.
- ****Histórico de Interações****:
 - **IDs de Músicas**: Lista de músicas com as quais o utilizador interagiu.
 - **Timestamps**: O momento em que a interação ocorreu.
 - **Classificações**: Feedback explícito ou implícito, como gostos, saltos ou número de reproduções.
- ****Dados Demográficos**** (opcional):
 - **Faixa Etária, Género, Região**.
- ****Padrões Comportamentais****:
 - **Sessões de Escuta**: Número de sessões e respetiva duração.
 - **Preferências de Género**: Extraídas a partir dos géneros das músicas ouvidas.

Propósito e Utilização

Este conjunto de dados desempenha um papel crítico em:

- Filtragem colaborativa, capturando interações entre utilizadores e itens.
- Compreender o comportamento dos utilizadores para personalizar recomendações dinamicamente.
- Reforçar modelos híbridos com dados comportamentais e demográficos.

Pré-processamento

Os passos de pré-processamento incluíram:

- Remoção de utilizadores inativos com dados mínimos de interação.
- Normalização de *timestamps* para fusos horários e formatos padrão.
- Conversão de feedback implícito (e.g., número de reproduções) em classificações numéricas, para compatibilidade com modelos de filtro colaborativo.

Integração dos Conjuntos de Dados

A combinação do ****conjunto de dados de músicas**** e do ****conjunto de dados de utilizadores**** é essencial para a construção de um algoritmo robusto de recomendação. Ao ligar as preferências dos utilizadores às características das músicas, o modelo pode aprender eficazmente a partir de sinais colaborativos e baseados em conteúdo, resultando em recomendações mais precisas e diversificadas.

6 Modelagem: Redes Neurais para Recomendação

Design do Modelo: Collaborative Filtering Neural

A abordagem inicial baseia-se em filtros colaborativos, implementados por meio de uma rede neuronal utilizando embeddings para representar users e produtos (músicas). O modelo foi estruturado como segue:

- **Camadas de Entrada**:
 - Uma camada de entrada para os IDs dos users.
 - Outra camada de entrada para os IDs dos produtos (músicas).
- **Embeddings e Transformações**: Cada entrada é transformada em embeddings densos de tamanho 50, representando os IDs como vetores contínuos. Após essa transformação, os vetores são redimensionados.
- **Operações de Similaridade**: Os vetores resultantes para users e produtos são combinados utilizando operações de produto interno (*dot product*) para calcular similaridades.
- **Camada de Saída**: Uma camada densa com ativação linear realiza a previsão da nota esperada do user para uma música.

Compilação do Modelo: O modelo foi compilado com o otimizador Adam, a função de perda de erro absoluto médio (MAE) e a métrica adicional de erro percentual absoluto médio (MAPE). Este design é conhecido como ****Collaborative Filtering Neural****.

253 **Design do Modelo: Neural Collaborative Filtering**
 254 Além do modelo baseado em filtros colaborativos, foi cri-
 255 ado um modelo mais avançado, combinando embeddings
 256 com uma rede neuronal densa para capturar interações mais
 257 complexas. Este modelo segue os mesmos princípios básicos
 258 de entrada e embeddings, mas adiciona:

- **Rede Neuronal Densa:** Os embeddings de users e produtos são concatenados e passados por uma camada densa com ativação ReLU, reduzindo dimensionalidades e permitindo aprender interações não lineares.
- **Combinação com Matriz de fatorização:** O modelo combina as saídas de um filtro colaborativo tradicional (usando produto interno) com as saídas da rede neuronal densa para gerar previsões mais robustas.

267 O modelo também foi compilado com os mesmos
 268 parâmetros do modelo anterior e avaliado com dados de
 269 validação.

270 Design do Modelo: Híbrido

271 Para um sistema de recomendação mais completo, foi de-
 272 desenvolvido um modelo híbrido que combina:

- **Filtro Colaborativo:** Embeddings de users e produtos.
- **Baseado em Conteúdo:** Informações sobre características das músicas (features).
- **Baseado em Contexto:** Contextos específicos relacionados a interações.

278 Estrutura do Modelo Híbrido:

- **Entrada Múltipla:** Inclui camadas de entrada separadas para users, produtos, características das músicas e contexto.
- **Camadas Densas:** Para as características e contextos, são utilizadas camadas densas com ativação ReLU para aprender representações relevantes.
- **Camada de Saída:** A saída combina as informações colaborativas, de conteúdo e contextuais para prever as notas dos users.

288 O modelo foi treinado por 100 vezes, com lote de tamanho
 289 128, e validado usando 30% dos dados de treino.

290 Treino e Avaliação

291 Os modelos foram treinados com o conjunto de treino
 292 utilizando *backpropagation* e avaliados em termos de
 293 perda (MAE) e erro percentual (MAPE). As curvas de
 294 aprendizagem mostraram convergência após um número
 295 razoável de épocas, indicando bom ajuste.

296 Os resultados demonstraram que a incorporação de redes
 297 neurais permitiu capturar relações mais complexas nos da-
 298 dos de recomendação, especialmente no modelo híbrido, que
 299 obteve melhor desempenho ao integrar múltiplas fontes de
 300 informação.

301 7 Resultados

302 content based normal, modelo collaborative filtering, neural
 303 collaborative filtering e Híbrido

Máximo número de registros por usuário:	985
Mínimo número de registros por usuário:	51
Média de registros por usuário:	379
Usuários com o máximo número de registros (985):	[31]
Usuários com o mínimo número de registros (51):	[128, 454]
Usuários com o número de registros igual à média (379):	[]

Table 1: Análise estatística da quantidade de músicas ouvidas de todos os users.




Figure 5: Comparação de ratings previstos pelo modelo Content Based com os originais




Figure 6: Análise das diferentes métricas pelos diferentes tamanhos do modelo Content Based




Figure 7: Comparação de ratings previstos pelo modelo Collaborative Filter com os originais




Figure 8: Análise das diferentes métricas pelos diferentes tamanhos do modelo Collaborative Filter




Figure 9: Comparação de ratings previstos pelo modelo Neural Filtering com os originais




Figure 10: Análise das diferentes métricas pelos diferentes tamanhos do modelo Neural Filtering

```
features = dtf_products.drop(["genres","name"], axis=1).columns
print(features)

context = dtf_context.drop(["user","product"], axis=1).columns
print(context)

✓ 0.0s

Index(['old', 'happy', 'dance rock', 'dutch cabaret', 'goth', 'dance pop',
      'r-n-b', 'latin', 'hard-rock', 'guitar',
      ...
      'romance', 'salsa', 'heavy-metal', 'piano', 'comedy', 'club',
      'album rock', 'party', 'sad', 'synth-pop'],
      dtype='object', length=126)
Index(['daytime', 'weekend'], dtype='object')
```

Figure 11: Dados usados no modelo Híbrido. Ao contrário dos outros modelos, o modelo híbrido analisa gênero por gênero e não por grupo de gêneros.




Figure 12: Comparação de ratings previstos pelo modelo híbrido com os originais




Figure 13: Análise das diferentes métricas pelos diferentes tamanhos do modelo híbrido

8 Análise dos Resultados

8.1 Modelo Content Based

- **Figura 5 e Figura 6:** A Figura 5 apresenta a comparação entre os *ratings* previstos pelo modelo Content Based e os valores reais. Observa-se que os valores previstos seguem a tendência geral dos valores reais, mas há flutuações, indicando que o modelo não captura perfeitamente as variações nos dados.

Já a Figura 6 analisa as métricas de desempenho (como erro ou precisão) em função do tamanho dos dados de treinamento. Os resultados sugerem que o modelo melhora à medida que o tamanho dos dados aumenta, com o desempenho estabilizando para conjuntos maiores.

8.2 Modelo Collaborative Filtering

- **Figura 7 e Figura 8:** Na Figura 7, observa-se a comparação dos *ratings* previstos pelo modelo Collaborative Filtering com os valores reais. Apesar de uma

tendência geral similar, nota-se maior dispersão em relação ao modelo Content Based.

A Figura 8 avalia o impacto do tamanho dos dados sobre o desempenho do modelo. O gráfico revela que o Collaborative Filtering é bastante sensível ao volume de dados, corroborando com a literatura que sugere que modelos colaborativos requerem grandes volumes para alcançar seu potencial máximo.

8.3 Modelo Neural Filtering

- **Figura 9 e Figura 10:** A Figura 9 mostra a comparação entre os *ratings* previstos pelo modelo Neural Filtering e os valores reais. Este modelo apresenta previsões mais consistentes em comparação aos modelos anteriores, capturando melhor a variação nos valores originais. Na Figura 10, observa-se a análise do impacto do tamanho dos dados sobre o desempenho do modelo. Nota-se que o Neural Filtering melhora rapidamente à medida que mais dados são adicionados, indicando sua eficácia na captura de padrões complexos.

8.4 Modelo Híbrido

- **Figura 11, Figura 12 e Figura 13:** A Figura 11 descreve os dados utilizados no modelo híbrido, destacando uma abordagem mais detalhada, que analisa gênero por gênero, em vez de trabalhar com grupos de gêneros.

A Figura 12 apresenta a comparação dos *ratings* previstos pelo modelo híbrido com os reais. Este modelo demonstra um alinhamento mais forte com os valores reais, indicando que combina com sucesso as vantagens dos modelos anteriores.

Na Figura 13, verifica-se a análise das métricas em função do tamanho dos dados. O modelo híbrido mostra-se o mais estável, com desempenho superior mesmo em cenários com menor volume de dados.

8.5 Conclusões Gerais

- **Content Based:** Apresenta bom desempenho ao capturar padrões baseados nas características dos itens, mas possui limitações em contextos de dados escassos ou em casos de itens novos.
- **Collaborative Filtering:** Depende de grandes volumes de dados para atingir bom desempenho. Enfrenta dificuldades em cenários de inicialização a frio (*cold start problem*).
- **Neural Filtering:** Mostra-se mais eficiente na captura de padrões complexos, com rápido ganho de desempenho à medida que mais dados são disponibilizados.
- **Modelo Híbrido:** Combina os pontos fortes dos modelos anteriores, oferecendo maior estabilidade e melhor desempenho geral, mesmo em condições de menor volume de dados.

9 Conclusão

O presente trabalho explorou a aplicação de redes neurais e técnicas de para a construção de um sistema de

recomendação de músicas, utilizando dados do Spotify. Desde a análise exploratória de dados até à implementação de modelos colaborativos e híbridos, os resultados demonstraram o potencial das abordagens baseadas em redes neurais para capturar padrões complexos nos dados e melhorar a experiência de recomendação.

As redes neurais colaborativas permitiram uma representação eficiente de users e músicas através de um sistema *embedding*, captando as interações entre eles. Já o modelo híbrido combinou informações de características musicais e o seu contexto, prometendo maior robustez em cenários com múltiplas dimensões de dados.

Os principais temas abordados no trabalho são os seguintes:

- A importância de uma análise exploratória detalhada com base em compreender a estrutura do conjunto de dados e identificar padrões relevantes.
- O impacto do design dos sistemas embeddings e da arquitetura das redes neurais na capacidade dos modelos de aprender interações significativas.
- A vantagem de modelos híbridos, que integram diferentes fontes de informação, na melhoria da precisão e personalização das recomendações.

Apesar dos resultados promissores, também surgem novos desafios, como o elevado custo computacional para treinar as redes neurais e a dificuldade em lidar com a escassez de dados para novos users e músicas (*cold-start problem*). Tais limitações podem ser abordadas em estudos futuros, integrando técnicas de ML por transferência ou incorporando dados de fontes externas.

Em resumo, este projeto destaca o valor de técnicas avançadas de ML no domínio de sistemas de recomendação de música, contribuindo para a personalização e qualidade da experiência do user. Estudos futuros podem expandir o modelo para incluir mais variáveis contextuais, como humor ou localização do user, além de explorar arquiteturas mais complexas, como redes neurais convolucionais e *transformers*, para capturar padrões ainda mais refinados.

References

- Gediminas Adomavicius and Alexander Tuzhilin. Toward the next generation of recommender systems: A survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6):734–749, 2005.
- Robin Burke, Alexander Felfernig, and Mehmet H Göker. 2361-Article Text-3699-1-10-20111031 (1). (1997):13–18, 2011.
- João Tomás Diogo Almeida, David Ferreira. Exploring Explainable Neural Networks for Spotify Music System Recommendation. pages 1–3.