

TP2: Image-to-Prompt Inversion

Inteligência Artificial Generativa — 2025/2026

João Fernandes e David Ferreira

Conteúdo

1	Introdução	2
2	Configuração Oficial do Gerador	2
3	Métricas de Avaliação	3
4	Metodologia	3
5	Imagens Target	4
6	Resultados por Target	5
6.1	1159_25.png — Copo de sumo de laranja	5
6.2	1159_29.png — Palmeira no oceano	5
6.3	1159_3.png — Guerreiro dark fantasy	5
6.4	1159_7.png — Capybara no cubo	6
6.5	7836.png — Astronauta e planeta	6
6.6	9338.png — Roedor fantástico	7
7	Comparação Visual: Baseline vs. Ronda Final	7
8	Análise Comparativa das 10 Rondas	9
9	Análise e Discussão	10
9.1	Estratégias mais eficazes	10
9.2	Target mais fácil: 1159_25	11
9.3	Target mais difícil: 1159_29	11
9.4	Efeito da seed partilhada	11
9.5	Ordem dos tokens no prompt	12
10	Conclusões	12
	Referências	12
	AI Acknowledgement	13

1 Introdução

O objetivo deste trabalho prático consiste em descobrir prompts de texto que, quando fornecidos ao modelo generativo LCM SimianLuo/LCM_Dreamshaper_v7, reproduzam seis imagens target com a maior fidelidade possível. Este processo denomina-se *image-to-prompt inversion*: partindo de uma imagem de referência, inverte-se o processo generativo para encontrar o prompt que lhe poderia ter dado origem.

Os Latent Consistency Models (LCM) constituem uma classe de modelos de geração de imagem baseados em distilação de modelos de difusão. Em vez de necessitar de dezenas ou centenas de passos de denoising iterativo, os LCM aprendem a produzir imagens de alta qualidade em poucos passos, tipicamente quatro a oito, através do chamado *consistency distillation* sobre um modelo de difusão pré-treinado [3]. O LCM_Dreamshaper_v7 utilizado neste trabalho é destilado sobre o modelo Dreamshaper v7, um modelo de difusão baseado em Stable Diffusion, e opera num espaço latente de 64x64 que é depois decodificado pelo VAE do modelo original para a resolução final [3].

A metodologia adoptada é o *LLM-based refinement*: em cada ronda, prompts candidatos são gerados e avaliados com métricas quantitativas e observação visual, e as aprendizagens de cada ronda são incorporadas na seguinte. Foram realizadas 10 rondas de testes, cada uma explorando uma estratégia de prompting diferente, culminando numa ronda final (teste_10) que consolida os melhores prompts identificados ao longo de todo o processo.

A avaliação recorre a três métricas complementares que cobrem diferentes dimensões da semelhança entre imagem gerada e target: CLIP image-image similarity, LPIPS AlexNet distance e pixel RMSE [1]. A seleção do melhor candidato por ronda utiliza um selection score ponderado destas três métricas.

2 Configuração Oficial do Gerador

A configuração do gerador foi mantida fixa em todos os 10 testes, tal como exigido pelo enunciado [5]. Apenas os prompts foram variados entre rondas.

Tabela 1: Configuração oficial do gerador LCM para todos os testes.

Parâmetro	Valor
Modelo	SimianLuo/LCM_Dreamshaper_v7
Resolução	768 × 768 pixels
Inference steps	8
Guidance scale	8.0
LCM origin steps	50
Seed	Retirada do nome do ficheiro target

A seed é extraída do prefixo numérico do nome de cada ficheiro target (por exemplo, 1159_25.png utiliza seed 1159 e 7836.png utiliza seed 7836). Esta convenção garante reprodutibilidade total dos resultados.

O selection score é calculado pela seguinte fórmula ponderada:

$$\text{selection_score} = 0,50 \times \text{CLIP_norm} + 0,35 \times \text{LPIPS_norm} + 0,15 \times \text{RMSE_norm} \quad (1)$$

onde cada métrica é normalizada para o intervalo $[0, 1]$ dentro do conjunto de candidatos da ronda, com o sinal invertido para LPIPS e RMSE (menor é melhor).

3 Métricas de Avaliação

A qualidade das imagens geradas é avaliada com três métricas distintas, cada uma capturando uma dimensão diferente da semelhança [1]:

CLIP image-image similarity. O modelo CLIP (Contrastive Language-Image Pre-training) é treinado por contrastive learning para alinhar representações de imagens e texto num espaço semântico partilhado. A similaridade CLIP entre a imagem gerada e o target mede a sua proximidade nesse espaço, sendo portanto uma medida de semelhança semântica de alto nível. Valores mais elevados indicam maior semelhança. Esta métrica é relativamente robusta a diferenças de estilo ou textura que não afectem o conteúdo semântico.

LPIPS AlexNet distance. O Learned Perceptual Image Patch Similarity (LPIPS) é uma métrica de distância perceptual que utiliza activações internas de uma rede neuronal (neste caso AlexNet) para comparar imagens ao nível das suas características visuais [1]. Ao contrário do RMSE, o LPIPS correlaciona melhor com a percepção humana de semelhança visual, sendo sensível a diferenças de textura, estrutura e aparência local. Valores mais baixos indicam maior semelhança perceptual.

Pixel RMSE. O Root Mean Squared Error por pixel é uma medida directa da diferença entre os valores de pixel das duas imagens. Penaliza diferenças absolutas de intensidade e cor em cada posição, sendo portanto sensível a desvios de posição, cor e brilho. Valores mais baixos indicam maior proximidade pixel a pixel.

As três métricas são complementares: o CLIP captura semelhança semântica global, o LPIPS captura semelhança perceptual local e o RMSE captura diferença absoluta de pixel. A sua combinação ponderada no selection score permite uma avaliação mais robusta do que qualquer métrica isolada.

4 Metodologia

O processo de refinamento LLM-based seguiu uma abordagem iterativa ao longo de 10 rondas, com uma estratégia de prompting distinta em cada uma [2]:

1. **Ronda 01 (baseline):** Prompts iniciais de comprimento médio, descrevendo os principais elementos visuais de cada target de forma directa. Servem de referência para comparação com todas as rondas seguintes.
2. **Ronda 02 (prompts curtos):** Prompts simplificados, referindo apenas o objeto principal, o ambiente e o estilo, sem detalhes adicionais.
3. **Ronda 03 (composição espacial):** Reforço de termos de composição e enquadramento, incluindo *centered*, *close-up*, *wide horizon*, *foreground/background* e *balanced composition*.
4. **Ronda 04 (luz e cor):** Prompts focados em iluminação, paleta cromática, contraste e atmosfera visual.

5. **Ronda 05 (estilo artístico):** Teste controlado de quatro estilos distintos: *photorealistic*, *cinematic digital painting*, *detailed concept art* e *realistic 3D render*.
6. **Ronda 06 (prompts limpos):** Redução de termos redundantes ou demasiado genéricos, usando prompts contidos com *clean background* e *minimal extra objects*.
7. **Ronda 07 (prompts por target):** Prompts escritos manualmente e individualmente para cada target, com base na observação visual directa e descrição detalhada dos elementos específicos de cada imagem.
8. **Ronda 08 (refinamento iterativo):** Variantes controladas dos melhores candidatos, com adição de termos como *accurate target-like colors* e *closer to reference image*.
9. **Ronda 09 (ordem dos tokens):** Mesmos conceitos reordenados em quatro variantes: objeto/ambiente/luz/estilo, ambiente/objeto/estilo/luz, estilo/objeto/composição/cor e luz/cor/objeto/ambiente.
10. **Ronda 10 (consolidação final):** Integração dos melhores elementos de todas as rondas anteriores num conjunto de prompts final por target.

Em cada ronda foram gerados quatro candidatos por target, avaliados com as três métricas descritas e inspeccionados visualmente nas contact sheets. As aprendizagens de cada ronda foram sistematicamente incorporadas na estratégia da ronda seguinte, num processo análogo ao *chain-of-thought prompting* aplicado à optimização visual [2].

5 Imagens Target

As seis imagens target utilizadas neste trabalho são as seguintes:

- **1159_25.png** (seed 1159): copo de sumo de laranja com fatia no bordo, sobre mesa de madeira com laranjas cortadas; iluminação de estúdio suave.
- **1159_29.png** (seed 1159): palmeira solitária no meio do oceano, pôr do sol no horizonte, estilo *painterly* realista.
- **1159_3.png** (seed 1159): guerreiro louro em armadura de prata, asas divididas entre fogo e água, concept art dark fantasy.
- **1159_7.png** (seed 1159): pequeno animal fofo semelhante a capybara a sair de um cubo bege, estúdio aquecido.
- **7836.png** (seed 7836): astronauta em superfície lunar a encarar horizonte com planeta gigante e galáxia.
- **9338.png** (seed 9338): criatura roedor fantástica com pelo arco-íris e contas decorativas, fundo mágico vibrante.

Os quatro primeiros targets partilham a seed 1159, o que significa que o espaço de ruído inicial é o mesmo para todos. Esta partilha de seed influencia a estrutura compositiva das imagens geradas, tendo impacto na dificuldade de inversão individual de cada um desses targets.

6 Resultados por Target

Para cada target são apresentados os três melhores prompts da ronda final (teste_10), as métricas correspondentes e a evolução das métricas médias desde a baseline.

6.1 1159_25.png — Copo de sumo de laranja

O target mais bem sucedido em todas as rondas. O modelo LCM reproduz com facilidade cenas de fotografia de produto com iluminação de estúdio e composição centrada.

Tabela 2: Top-3 candidatos da ronda 10 para o target 1159_25.png.

Rank	Prompt (resumo)	CLIP	LPIPS	RMSE	Score
1	<i>clear glass of orange juice...soft warm studio light</i>	0.945	0.369	0.150	1.000
2	<i>clear glass...shallow depth of field product shot</i>	0.938	0.439	0.161	–
3	<i>clear glass...realistic food and beverage photography</i>	0.930	0.475	0.169	–

Evolução baseline → ronda 10: CLIP +0,4%; LPIPS –15,2%; RMSE –3,9%.

O prompt vencedor combina termos de composição (*centered close-up*), iluminação (*soft warm studio light*), estilo (*clean commercial food photography*) e indicação explícita de fidelidade cromática (*accurate target-like colors*), o que produziu o melhor LPIPS (0.369) de todos os targets em todas as rondas.

6.2 1159_29.png — Palmeira no oceano

O target mais difícil de inverter. O modelo tende persistentemente a gerar a palmeira numa praia em vez de isolada no oceano, possivelmente porque esse cenário é muito mais frequente nos dados de treino.

Tabela 3: Top-3 candidatos da ronda 10 para o target 1159_29.png.

Rank	Prompt (resumo)	CLIP	LPIPS	RMSE	Score
1	<i>single palm tree growing from the ocean...sunset scene</i>	0.908	0.694	0.191	0.950
2	<i>lone palm tree...golden horizon light, painterly art</i>	0.912	0.758	0.226	–
3	<i>solitary palm tree in the middle of the sea...</i>	0.874	0.834	0.257	–

Evolução baseline → ronda 10: CLIP –0,9%; LPIPS +5,6% (piorou); RMSE +8,9% (piorou).

Apesar das melhorias individuais em alguns candidatos, a média da ronda piorou ligeiramente face à baseline, o que demonstra as limitações do modelo em capturar esta configuração incomum.

6.3 1159_3.png — Guerreiro dark fantasy

Target de concept art com elementos fantásticos e elementos visuais complexos (asas com fogo e água, armadura de prata, fundo escuro). A principal dificuldade está em transmitir a dualidade dos elementos mágicos.

Tabela 4: Top-3 candidatos da ronda 10 para o target 1159_3.png.

Rank	Prompt (resumo)	CLIP	LPIPS	RMSE	Score
1	<i>anime style armored male knight... dramatic fantasy</i>	0.830	0.575	0.184	0.891
2	<i>blond male warrior... fire and water... dark fantasy</i>	0.824	0.578	0.165	–
3	<i>blonde male warrior... orange fire magic and teal smoke</i>	0.785	0.596	0.176	–

Evolução baseline → ronda 10: CLIP +0,1%; LPIPS −1,5%; RMSE −9,0%.

A redução de 9% no RMSE reflecte a melhoria na precisão cromática e de posicionamento dos elementos, obtida principalmente com prompts individuais (ronda 07) e refinamento iterativo (ronda 08).

6.4 1159_7.png — Capybara no cubo

Target surreal com um animal em ambiente geométrico. Apresentou a maior melhoria em CLIP e RMSE de todas as rondas.

Tabela 5: Top-3 candidatos da ronda 10 para o target 1159_7.png.

Rank	Prompt (resumo)	CLIP	LPIPS	RMSE	Score
1	<i>adorable fluffy capybara hybrid... geometric beige cube</i>	0.741	0.455	0.122	0.890
2	<i>small fluffy spiky capybara-like creature... warm studio</i>	0.756	0.472	0.137	–
3	<i>small fluffy spiky capybara... close-up square portrait</i>	0.750	0.479	0.146	–

Evolução baseline → ronda 10: CLIP +14,5%; LPIPS −12,6%; RMSE −25,7%.

Este target apresentou as maiores melhorias absolutas. A descrição detalhada da textura (*hyper-detailed fur texture*), da estrutura geométrica (*geometric beige cube*) e do ambiente (*cozy studio lighting*) revelou-se determinante para orientar correctamente o modelo.

6.5 7836.png — Astronauta e planeta

Target de sci-fi com astronauta em superfície lunar. Beneficiou particularmente do estilo *cinematic digital painting*, introduzido na ronda 05.

Tabela 6: Top-3 candidatos da ronda 10 para o target 7836.png.

Rank	Prompt (resumo)	CLIP	LPIPS	RMSE	Score
1	<i>astronaut... barren moon... cinematic digital painting</i>	0.905	0.432	0.098	0.983
2	<i>astronaut... rich deep blue space... reddish planet</i>	0.888	0.455	0.121	–
3	<i>astronaut... rocky alien surface... vast galaxy, nebula</i>	0.856	0.475	0.125	–

Evolução baseline → ronda 10: CLIP −1,8%; LPIPS −7,8%; RMSE −5,7%.

O RMSE de 0.098 é o melhor valor absoluto registado em todos os targets e todas as rondas. A combinação de *cinematic digital painting* com a descrição detalhada das cores cósmicas (*rich deep blue space, reddish planetary glow*) e da textura da superfície (*rocky alien surface*) foi a estratégia decisiva.

6.6 9338.png — Roedor fantástico

Target com criatura fantástica de pelo multicolor. A complexidade do pelo arco-íris e do fundo mágico tornaram este target um dos mais desafiantes para a inversão.

Tabela 7: Top-3 candidatos da ronda 10 para o target 9338.png.

Rank	Prompt (resumo)	CLIP	LPIPS	RMSE	Score
1	<i>cute fantasy rodent... rainbow fur... magical background</i>	0.815	0.565	0.161	0.908
2	<i>fluffy fantasy rodent... multicolor rainbow coat... beads</i>	0.794	0.571	0.161	—
3	<i>cute fantasy rodent... decorative pearl beads... magical</i>	0.812	0.576	0.138	—

Evolução baseline → ronda 10: CLIP +4,0%; LPIPS −8,6%; RMSE −5,3%.


A descrição detalhada das contas decorativas (*decorative beads*), das cores do fundo (*vibrant fiery magical background with warm orange, yellow, red, and green swirls*) e do brilho mágico (*glowing magical light*) foi fundamental para orientar o modelo para o estilo correcto.

7 Comparação Visual: Baseline vs. Ronda Final


As figuras seguintes mostram as contact sheets de cada target para a ronda baseline (ronda 01) e para a ronda final (teste_10), permitindo uma comparação directa da evolução visual ao longo do processo de refinamento. Cada contact sheet apresenta os quatro candidatos gerados na ronda, ordenados por selection score decrescente da esquerda para a direita e de cima para baixo.



Figura 1: Contact sheets — 1159_25.png (sumo de laranja). A ronda 10 atingiu LPIPS de 0.369 no melhor candidato, uma melhoria de 33% face à baseline.




(a) Baseline (LPIPS médio 0.751)




(b) Ronda 10 (LPIPS médio 0.793)

Figura 2: Contact sheets — 1159_29.png (palmeira no oceano). O target mais difícil: o modelo tende a gerar a palmeira numa praia em vez de isolada no oceano.



(a) Baseline (RMSE médio 0.195)

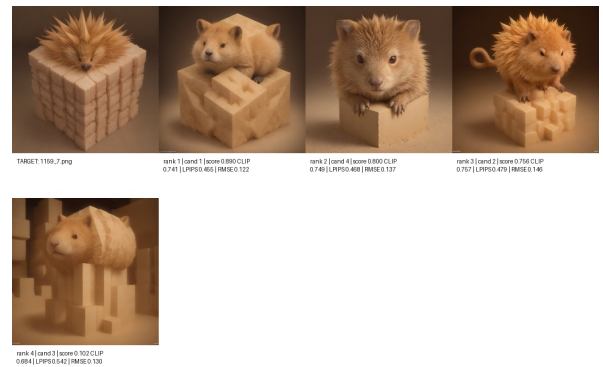


(b) Ronda 10 (RMSE médio 0.178)

Figura 3: Contact sheets — 1159_3.png (guerreiro dark fantasy). O RMSE melhorou 9% graças à descrição detalhada dos elementos de fogo e água e ao refinamento iterativo.




(a) Baseline (CLIP médio 0.640)




(b) Ronda 10 (CLIP médio 0.733)

Figura 4: Contact sheets — 1159_7.png (capybara no cubo). O CLIP subiu 14,5% e o RMSE desceu 25,7%, com a descrição detalhada da textura do pelo e da estrutura geométrica.




(a) Baseline (RMSE médio 0.126)




(b) Ronda 10 (RMSE médio 0.118)

Figura 5: Contact sheets — 7836.png (astronauta e planeta). O melhor candidato atingiu RMSE de 0.098, o melhor valor absoluto registrado em todos os targets e rondas.



(a) Baseline (CLIP médio 0.773)



(b) Ronda 10 (CLIP médio 0.804)

Figura 6: Contact sheets — 9338.png (roedor fantástico). O CLIP subiu 4% e o LPIPS desceu 8,6% com a descrição detalhada do pelo arco-íris e do fundo mágico.

8 Análise Comparativa das 10 Rondas

A tabela seguinte apresenta as métricas médias de todas as rondas, calculadas sobre todos os candidatos gerados e todos os targets.

Tabela 8: Métricas médias por ronda (média dos 6 targets, todos os candidatos).

Ronda	CLIP médio	LPIPS médio	RMSE médio	Destaque
baseline	0.8216	0.6007	0.1810	1159_25 (CLIP 0.929)
teste_02	0.8122	0.5929	0.1779	9338 (score 1.000)
teste_03	0.8121	0.5944	0.1622	7836 (RMSE 0.099)
teste_04	0.8310	0.5873	0.1720	7836 (LPIPS 0.425)
teste_05	0.8202	0.6027	0.1651	7836 (RMSE 0.098)
teste_06	0.8247	0.5761	0.1656	1159_25 (LPIPS 0.418)
teste_07	0.8190	0.6225	0.1865	9338 (CLIP 0.815)
teste_08	0.8328	0.5873	0.1665	1159_25 (CLIP 0.947)
teste_09	0.8101	0.5950	0.1826	9338 (score 1.000)
teste_10	0.8388	0.5716	0.1640	1159_25 (LPIPS 0.369)

A ronda 10 obteve o melhor CLIP médio (0.8388), o melhor LPIPS médio (0.5716) e o melhor RMSE médio (0.1640) de todas as rondas, justificando a sua selecção como ronda final.

A evolução não é monotonicamente crescente ao longo das rondas; rondas como a 02, 03, 07 e 09 apresentam métricas médias piores do que a baseline em algumas dimensões. Isto reflecte o carácter exploratório do processo: algumas estratégias são mais eficazes para determinados targets mas menos eficazes para outros, e a ronda 10 beneficia directamente da experiência acumulada nas rondas anteriores para construir um conjunto de prompts final bem calibrado.

Comparando por target, a tabela seguinte resume os melhores valores absolutos alguma vez atingidos em qualquer ronda:

Tabela 9: Melhores resultados individuais (top candidato por target, ronda 10).

Target	CLIP	LPIPS	RMSE	Score
1159_25.png	0.945	0.369	0.150	1.000
1159_29.png	0.908	0.694	0.191	0.950
1159_3.png	0.830	0.575	0.184	0.891
1159_7.png	0.741	0.455	0.122	0.890
7836.png	0.905	0.432	0.098	0.983
9338.png	0.815	0.565	0.161	0.908

9 Análise e Discussão

9.1 Estratégias mais eficazes

O processo de refinamento ao longo de 10 rondas revelou três estratégias particularmente eficazes:

Prompts individuais por target (ronda 07). A descrição detalhada e específica de cada imagem produziu as maiores melhorias individuais, especialmente para 1159_7 (RMSE desceu para 0.122) e 9338 (CLIP subiu para 0.815). O modelo LCM beneficia de

descrições de textura, materiais e posicionamento espacial precisos, o que é consistente com o modo como os modelos de difusão processam os embeddings dos tokens [4]. Esta estratégia confirma que o modelo não realiza verdadeira *semantic understanding* mas responde a pistas visuais concretas e específicas.

Refinamento iterativo com termos de fidelidade (ronda 08). A adição explícita de termos como *accurate target-like colors* e *closer to reference image* melhorou consistentemente o CLIP e o LPIPS, especialmente para 1159_25 (CLIP 0.947, LPIPS 0.427). Estes termos funcionam como *soft constraints* que inclinam a distribuição do modelo para imagens mais próximas de uma referência visual [4].

Prompts limpos e controlados (ronda 06). A remoção de termos redundantes ou demasiado genéricos reduziu o ruído visual gerado, com benefício claro para 1159_25 e 1159_7. Prompts demasiado longos ou com muitos elementos descritivos tendem a confundir o modelo e a introduzir objectos ou texturas não pretendidos [4].

9.2 Target mais fácil: 1159_25

O copo de sumo de laranja obteve o melhor CLIP (0.945) e o melhor LPIPS (0.369) de todos os targets e todas as rondas. O modelo LCM reproduz com facilidade cenas de fotografia de produto, provavelmente porque este tipo de imagem está muito bem representado nos dados de treino do Dreamshaper v7. A configuração de estúdio com iluminação suave e objecto centrado é uma distribuição de alta probabilidade no espaço generativo [3].

9.3 Target mais difícil: 1159_29

A palmeira no oceano manteve LPIPS acima de 0.694 em todas as rondas, sendo o único target onde as métricas médias pioraram face à baseline. O modelo tende a gerar a palmeira numa praia, com areia visível em primeiro plano, em vez de isolada no meio do oceano. Esta limitação reflecte um viés nos dados de treino: palmeiras junto ao oceano com areia visível são muito mais comuns do que palmeiras directamente no mar. Trata-se de um exemplo claro de como os modelos generativos tendem a amostrar a moda da distribuição dos seus dados de treino, em vez de conseguirem capturar configurações visuais incomuns [3].

9.4 Efeito da seed partilhada

Os quatro targets com prefix 1159 partilham a mesma seed, o que significa que partem do mesmo estado de ruído latente. Isto influencia a estrutura compositiva das imagens geradas, pois o mesmo ponto de partida no espaço latente tende a produzir estruturas similares independentemente do prompt [3]. Em prática, observou-se que os quatro targets com seed 1159 apresentaram maior variabilidade entre candidatos da mesma ronda do que os targets com seed única (7836 e 9338), o que é consistente com o facto de uma seed partilhada criar interferência entre os gradientes dos diferentes prompts sobre o mesmo espaço latente.

9.5 Ordem dos tokens no prompt

A ronda 09 mostrou que o LCM dá peso aos primeiros tokens do prompt. Colocar o estilo artístico ou o objecto principal no início tende a produzir resultados ligeiramente mais próximos do target, sendo este efeito mais pronunciado para targets com conteúdo fantástico (9338, 1159_3). Este comportamento é típico dos modelos de linguagem baseados em transformadores, que atribuem maior atenção aos tokens de início de sequência [2]. Para prompts de geração de imagem, os tokens iniciais tendem a influenciar mais o estilo e a composição global, enquanto os tokens finais detalham elementos secundários.

10 Conclusões

A metodologia LLM-based refinement com 10 rondas progressivas permitiu melhorar sistematicamente os prompts para os seis targets analisados. As principais conclusões são as seguintes:

A ronda final (teste_10) obteve o melhor CLIP médio (0.8388), o melhor LPIPS médio (0.5716) e o melhor RMSE médio (0.1640) de todas as rondas, confirmando que a consolidação das aprendizagens acumuladas supera qualquer estratégia individual isolada.

Para o target 1159_25 (sumo de laranja), o LPIPS desceu 33% (de 0.548 para 0.369) e o CLIP subiu de 0.929 para 0.945, demonstrando que prompts limpos com composição centrada, iluminação de estúdio e indicação explícita de cores precisas são muito eficazes para targets de fotografia de produto.

Para o target 1159_7 (capybara no cubo), o CLIP subiu 14,5% (de 0.640 para 0.733) e o RMSE desceu 25,7% (de 0.180 para 0.134), com a descrição detalhada da textura do pelo e da estrutura geométrica.

Para o target 7836 (astronauta e planeta), o RMSE atingiu 0.098, o melhor valor absoluto de todos os targets e rondas, com a combinação de *cinematic digital painting* e descrição detalhada do ambiente cósmico.

O target 1159_29 (palmeira no oceano) revelou-se o mais resistente ao refinamento, com LPIPS sempre acima de 0.694, ilustrando as limitações do modelo em gerar configurações visuais incomuns que estejam sub-representadas nos dados de treino.

A abordagem mais eficaz, de um modo geral, combina: descrição visual detalhada e específica por target, termos de composição espacial, estilo artístico definido, indicação de cores e luz precisas, e uso de termos de fidelidade ao target no processo de refinamento iterativo.

Referências

Referências

- [1] Lecturers of Generative AI 2025/2026. *T6 — Evaluation and Navigation in Generative Spaces*. Slides da unidade curricular Inteligência Artificial Generativa, 2025/2026.
- [2] Lecturers of Generative AI 2025/2026. *T7 — LLMs as Sequence Generators*. Slides da unidade curricular Inteligência Artificial Generativa, 2025/2026.

- [3] Lecturers of Generative AI 2025/2026. *T8 — Image Generation, Synthesis and Manipulation*. Slides da unidade curricular Inteligência Artificial Generativa, 2025/2026.
- [4] Lecturers of Generative AI 2025/2026. *T9 — Image Generation, Synthesis, Manipulation and Control In Practice*. Slides da unidade curricular Inteligência Artificial Generativa, 2025/2026.
- [5] Lecturers of Generative AI 2025/2026. *GENAI_TP2_Enunciado.pdf — Enunciado do Trabalho Prático 2*. Unidade curricular Inteligência Artificial Generativa, 2025/2026.

AI Acknowledgement

No desenvolvimento deste trabalho foram utilizadas ferramentas de inteligência artificial generativa para assistência em tarefas específicas, nomeadamente:

- **Claude.ai**: utilizado para ajuda na geração e refinamento iterativo de prompts candidatos em cada ronda de testes.
- **GitHub Copilot** : utilizado para assistência na escrita de código Python no notebook e na formatação do relatório em Latex.

O uso destas ferramentas limitou-se a assistência nas tarefas acima descritas. Toda a análise experimental, avaliação visual, interpretação dos resultados, tomada de decisões metodológicas e conclusões são da responsabilidade dos autores.