

Universidade de Coimbra
Faculdade de Ciências e Tecnologia
Departamento de Engenharia Informática

Startup Investment Ecosystem

Analyzing Funding Patterns and Predicting Success

Tecnologias e Análise de Dados
2025/2026

Autores: David João Pinto Ferreira — 2020248052
João Tomás Cardoso Fernandes — 2021219036

Coimbra, Maio de 2026

Conteúdo

1	Introdução	2
1.1	Questões de Investigação	2
2	Dados	2
2.1	Dataset	2
2.2	ETL	3
3	Arquitetura da Pipeline	4
3.1	Componentes	4
4	<i>Data Warehouse</i>	4
4.1	<i>Star Schema</i>	4
4.2	Tabelas	5
4.3	Tabelas ML	5
5	Queries OLAP	6
6	Data Mining: Classificação Preditiva	6
6.1	Definição do Problema	6
6.2	Preparação dos Dados	6
6.2.1	Seleção de Features	6
6.2.2	Dataset	6
6.2.3	Tratamento de Desbalanceamento: SMOTE	6
6.3	Modelos Treinados	7
6.4	Resultados	7
7	Data Mining: Clustering	8
7.1	Definição do Problema	8
7.2	Features Utilizadas	8
7.3	Seleção de K	8
7.4	Perfil dos Clusters	9
8	Dashboards Power BI	10
9	Conclusões	11
9.1	Principais Resultados	11
9.2	Limitações	12
9.3	Trabalho Futuro	12
10	Referências	12
11	Acknowledgements	13

1 Introdução

No ramo empresarial, sobretudo em novas empresas (start-ups), existe muita informação e conclusões acerca de quais são os melhores mercados ou países para investir. Contudo, a taxa de insucesso e o tipo de alocação de capital são métricas muito importantes para o investidor entender o potencial de retorno, tendo assim como objetivo start-ups que foram adquiridas ou ainda estão a operar.

O ecossistema global de startups tem registado um crescimento exponencial nas últimas décadas em empresas e mercados emergentes. Compreender os padrões de investimento, os fatores que influenciam o sucesso e os perfis distintos de startups é fundamental tanto para investidores como para empreendedores.

Este projeto implementa uma plataforma analítica completa que explora dados de investimento do Crunchbase, abrangendo aproximadamente 54 000 empresas fundadas entre 1990 e 2014. A plataforma é composta por uma pipeline de *ETL* implementada em *Databricks* com *PySpark*; Um *Data Warehouse* em estrela (*Star Schema*) em *PostgreSQL*; *Queries OLAP* para análise descritiva e diagnóstica; Modelos de classificação para previsão de sucesso; *Clustering* para segmentação de startups; E por fim, vários *Dashboards* interativos em *Power BI*.

1.1 Questões de Investigação

1. Quais são os mercados e geografias que atraem mais capital de risco?
2. Como evoluiu o investimento em startups ao longo do tempo?
3. Que fatores (tipo de funding, mercado, localização) estão associados a maior probabilidade de aquisição?
4. É possível prever o outcome de uma startup (adquirida vs. encerrada) com base nas suas características de investimento?
5. Existem perfis distintos de startups com base nos seus padrões de financiamento?

2 Dados

2.1 Dataset

O dataset utilizado provém do Crunchbase, disponibilizado no Kaggle¹, e contém várias informações sobre as startups. O ficheiro original (*investments_VC.csv*) possui 54 294 registos com os seguintes atributos principais:

¹<https://www.kaggle.com/datasets/arindam235/startup-investments-crunchbase>

Tabela 1: Atributos principais do dataset

Atributo	Descrição
permalink, name	Identificador único e nome da empresa
homepage_url	URL do website
category_list	Categorias de mercado
market	Mercado principal
funding_total_usd	Total de financiamento obtido (USD)
status	Estado atual: <i>acquired</i> , <i>closed</i> , <i>operating</i> , <i>unknown</i>
country_code, state_code, city	Localização geográfica
region	Região geográfica
funding_rounds	Número de rondas de financiamento
founded_at	Data de fundação
first_funding_at, last_funding_at	Datas de primeiro e último financiamento
seed, venture, angel, ...	Montantes por tipo de financiamento (21 tipos)
round_A a round_H	Montantes por série de investimento

2.2 ETL

A extração dos dados é realizada no Databricks com *PySpark*. O dataset sofre diferentes transformações, tais como eliminar registos vazios (linhas sem `name` nem `permalink`) e duplicados, como forma de obter um dataset sem ruído. Os valores relacionados com os montantes sofreram uma normalização (remoção de vírgulas, conversão para `DOUBLE`), tal como as datas (conversão para tipo `DATE`, filtragem de registos anteriores a 1990). Como enriquecimento dos dados, houve um mapeamento de continentes (50+ códigos de país), cálculo de `market_group` e a criação de colunas derivadas (`num_funding_types`, `has_seed`, `has_venture`, `has_series_a_plus`, `years_to_first_funding`).

Após limpeza, o dataset resultante contém 48 440 registos válidos. Apesar do tratamento e preparação, este dataset contém um problema, relacionado com o estado atual da startup. Em alguns casos, não é conhecido o estado da startup. Estes valores foram mantidos pois consideramos que não iria afetar os futuros modelos, devido ao baixo volume de situações comparativamente.

É executado o carregamento, produzindo 6 tabelas que são guardadas e exportadas como CSV:

Tabela 2: Tabelas produzidas pela pipeline ETL

Tabela	Linhas	Colunas
staging_raw_investments	48 440	45
dim_time	4 363	8
dim_location	4 709	6
dim_market	17 276	4
dim_status	4	3
fact_investments	48 440	38

3 Arquitetura da Pipeline

A arquitetura segue um modelo de pipeline de dados com dois outputs paralelos, conforme ilustrado na Figura 1.




Figura 1: Arquitetura da pipeline de dados

3.1 Componentes

Tabela 3: Componentes da plataforma

Componente	Descrição
ETL Pipeline	Extração do CSV e transformação com PySpark no Databricks
Data Warehouse	Star Schema em PostgreSQL: 1 tabela de factos + 4 dimensões
SQL Views	4 vistas analíticas pré-construídas para OLAP
OLAP Queries	SQL queries: descritivas (Q1–Q6) e diagnósticas (Q7–Q11)
Data Mining	Classificação (3 modelos + SMOTE) e Clustering (K-Means)
ML → DW	Resultados ML armazenados em 5 tabelas no PostgreSQL
Power BI	Dashboards interativos ligados ao PostgreSQL

4 Data Warehouse

4.1 Star Schema

O *Data Warehouse* segue uma arquitetura em estrela (*Star Schema*) com uma tabela de factos central e quatro dimensões. O diagrama conceptual é apresentado na Figura 2.




Figura 2: Diagrama conceitual do Star Schema

4.2 Tabelas

A tabela **fact_investments** contém 48 440 registos, cada um representando uma empresa com os seus dados de investimento. As métricas incluem o **funding_total_usd** (Total de capital obtido), **funding_rounds** (Número de rondas de financiamento) e 21 colunas de montantes por tipo (seed, venture, angel, round_A a round_H, etc.).

A tabela **dim_time** (4 363 linhas) tem os registos temporais com diferentes granularidades, tais como a diária, com os atributos ano, trimestre, mês, década e **is_pre_2000**.

A tabela **dim_location** (4 709 linhas) possui a hierarquia geográfica completa desde o continente, país, estado, região, até à cidade.

A tabela **dim_market** (17 276 linhas) contém as informações do mercado principal, lista de categorias e grupo de mercado.

Por fim, a tabela **dim_status** (4 linhas) guarda os estados possíveis (*acquired*, *closed*, *operating*, *unknown*) e o sucesso das startups (**is_successful**).

4.3 Tabelas ML

Para integrar os resultados de Data Mining no DW, foram criadas 5 tabelas adicionais:

Tabela 4: Tabelas de resultados ML no DW

Tabela	Linhas	Conteúdo
ml_predictions	6 152	Previsão por startup (acquired/closed + probabilidades)
ml_cluster_assignments	40 130	Cluster atribuído a cada startup
ml_cluster_profiles	10	Perfil agregado de cada cluster
ml_model_metadata	4	Métricas dos modelos (AUC, F1, silhouette)
ml_feature_importance	–	Importância das features do melhor modelo

5 Queries OLAP

Foram implementadas 11 queries OLAP organizadas em dois grupos. As descritivas têm como função identificar os mercados que mais atraem capital, a evolução temporal do funding, o funding por país e a distribuição de status. As diagnósticas são executadas para comparar o funding e rondas médias por status, filtrar empresas consoante as taxas de sucesso e relacionar os tipos de funding por estado da startup.

6 Data Mining: Classificação Preditiva

6.1 Definição do Problema

O objetivo é prever o outcome de uma startup como *acquired* (adquirida) ou *closed* (encerrada), com base nas suas características. Trata-se de um problema de classificação binária supervisionada, com o objetivo de auxiliar o investidor a entender melhor a probabilidade do sucesso da startup.

6.2 Preparação dos Dados

6.2.1 Seleção de Features

Foram aplicadas 63 features para este problema, estando estas separadas em 3 grupos, as features numéricas (relacionadas com os investimentos, relativamente ao montante, rondas de investimento, etc), as features binárias (has_seed, has_venture, has_series_a_plus) e as features categóricas (Top 30 mercados, Top 10 países, 7 continentes).

6.2.2 Dataset

Foram selecionadas apenas as empresas com status *acquired* ou *closed* num total de 6 152 amostras (3 571 acquired, 2 581 closed).

6.2.3 Tratamento de Desbalanceamento: SMOTE

Devido ao desbalanceamento entre classes, foi aplicado SMOTE (*Synthetic Minority Over-sampling Technique*) apenas ao conjunto de treino para evitar data leakage.

6.3 Modelos Treinados

Foram treinados três modelos (Logistic Regression, Random Forest e Gradient Boosting) com uma partição de 80% treino e 20% teste (com estratificação por classe), tendo sido aplicado com a seguinte pipeline:

Imputação (mediana) → Scaling (StandardScaler) → SMOTE → Modelo

Os valores em falta são preenchidos com a mediana de cada feature e depois todas as features são normalizadas com StandardScaler. De seguida, aplica-se SMOTE apenas ao conjunto de treino para equilibrar as classes (acquired vs. closed), e os dados balanceados são usados para treinar o modelo de classificação.

6.4 Resultados

Tabela 5: Resultados dos modelos de classificação

Modelo	AUC	F1-Score	Accuracy
Logistic Regression	0.69	0.77	0.72
Random Forest	0.72	0.77	0.76
Gradient Boosting	0.71	0.78	0.75

O Gradient Boosting foi selecionado como melhor modelo com base no AUC (*Area Under the ROC Curve*), sendo o mais capaz de discriminar entre startups adquiridas e encerradas.





Figura 3: Curvas ROC dos três modelos de classificação



(a) Matriz de confusão do Gradient Boosting

(b) Importância das features (Top 20)

Figura 4: .-.

7 Data Mining: Clustering

7.1 Definição do Problema

O objetivo é segmentar startups em grupos homogêneos com base nos seus padrões de financiamento, utilizando K-Means clustering. Foram consideradas todas as startups com $funding_total_usd > 0$.

7.2 Features Utilizadas

Todas as features foram standardizadas com **StandardScaler** antes do clustering, sendo estas os montantes de funding, o número de rondas de funding, o total de tipos fundings e se receberam seed ou venture ou mais de uma seed.

7.3 Seleção de K

A seleção do número ótimo de clusters combina o método do cotovelo (inércia) com a análise de silhouette.

Tabela 6: Avaliação de K (amostra de resultados)

K	Inércia	Silhouette
2	364 861	0.3316
3	287 943	0.3570
4	233 376	0.4012
5	195 181	0.4292
6	171 237	0.4500
7	148 333	0.4659
8	133 306	0.4931
9	119 559	0.5075
10	107 570	0.5411

O K ótimo selecionado foi 10, com silhouette score de 0.5411.




Figura 5: Método do cotovelo e análise de silhouette

7.4 Perfil dos Clusters

A Tabela 7 apresenta o perfil de cada cluster identificado.

Tabela 7: Perfil dos clusters (K=10)

Cluster	Count	Avg Funding	Med. Funding	Avg Rnds	% Acq	Market	País
0	9 463	10.1M	2.6M	1.57	6.4%	Biotech	USA
1	10 608	0.8M	0.3M	1.33	3.3%	Software	USA
2	1 933	8.9M	4.1M	3.06	7.1%	Software	USA
3	4 511	9.1M	4.6M	1.59	11.2%	Software	USA
4	1 263	92.4M	53.0M	4.61	21.2%	Biotech	USA
5	1 920	44.7M	28.8M	3.34	21.7%	Biotech	USA
6	4 326	31.0M	0.9M	1.25	3.9%	Biotech	USA
7	1 644	18.4M	10.0M	1.97	15.5%	Software	USA
8	1 925	25.9M	16.6M	3.17	17.1%	Software	USA
9	1 920	44.7M	28.8M	3.34	21.7%	Biotech	USA

Os clusters revelam perfis distintos de startups:

- **Clusters 4, 5, 9** (High-value late-stage): Funding médio >40M USD, múltiplas rondas, taxa de aquisição >21%, representam startups maduras com forte tracção;
- **Cluster 1** (Early-stage bootstrap): Funding médio <1M USD, poucas rondas, taxa de aquisição mais baixa (3.3%), startups em fase inicial;
- **Clusters 3, 7, 8** (Growth-stage): Funding intermédio (9 - 26M), 2- 3 rondas, taxas de aquisição moderadas (11 - 17%), startups com funcionamento normal;
- **Cluster 6** (Capital-intensive early): Funding médio alto (31M) mas mediana baixa (0.9M), sugerindo distribuição muito assimétrica com poucos outliers de alto valor.





Figura 6: Clusters projetados em espaço PCA (2 componentes)



(a) Tamanho dos clusters

(b) Radar chart dos perfis

Figura 7: Análise visual dos clusters

8 Dashboards Power BI

O Power BI liga-se diretamente ao PostgreSQL e consome tanto as tabelas/vistas OLAP como os resultados ML. O dashboard está organizado em 7 páginas:

Página 1: Overview - Contém uma visão geral dos dados.




Figura 8: Página da Overview

Página 2: Time Analysis - A partir de um filtro temporal é possível visualizar a evolução do funding ao longo dos anos.

Página 3: Geo Analysis - Sendo possível escolher entre diferentes países ou continentes, contém diferentes gráficos com informação de funding e percentagem de aquisição, sendo possível comparar essas informações.

Página 4: Diagnostic - Demonstra comparações diretas entre mercado vs sucesso e funding vs sucesso.

Página 5: Predictions - Contém informações relativamente à performance dos modelos de previsão.

Página 6: Clustering - Demonstra os resultados obtidos através do modelo de clustering.

Página 7: Simulator - Simulador que determina se a startup tem sucesso ou não consoante os parametros seleccionados.

9 Conclusões

Este projeto demonstra a implementação completa de uma plataforma analítica para o ecossistema de startups, desde a ingestão e transformação dos dados até à visualização interativa dos resultados.

9.1 Principais Resultados

1. **Concentração geográfica:** Os EUA dominam o ecossistema de venture capital, representando a maioria do capital investido e das startups fundadas;
2. **Software e Biotecnologia:** São os mercados dominantes tanto em volume de investimento como em número de empresas;
3. **Previsão de sucesso:** O modelo Gradient Boosting atinge um AUC de 0.78, demonstrando que o outcome de uma startup pode ser parcialmente previsto com base em características de investimento;

4. **Features mais relevantes:** O total de funding, o tempo até primeiro financiamento e o ano de fundação são os preditores mais fortes;
5. **Diversidade de funding:** Startups com maior diversidade de tipos de financiamento tendem a ter melhores outcomes;
6. **Segmentação:** O clustering K-Means identifica perfis distintos, desde bootstraps iniciais a startups maduras com múltiplas rondas e alta probabilidade de aquisição;
7. **Seed funding:** Empresas com seed funding têm maior probabilidade de progredir para séries subsequentes.

9.2 Limitações

- O dataset cobre apenas até 2014, não refletindo tendências mais recentes;
- O status “operating” não indica sucesso definitivo, muitas empresas operacionais podem vir a ser adquiridas ou encerradas;
- O AUC de 0.78 é razoável mas indica que fatores não capturados nos dados (e.g., qualidade da equipa, mercado-alvo, timing) são relevantes.

9.3 Trabalho Futuro

- Incorporar dados mais recentes do Crunchbase;
- Adicionar análise de séries temporais para prever tendências de mercado;
- Explorar modelos de deep learning (e.g., redes neuronais) para melhorar a classificação;
- Implementar análise de texto (NLP) nas descrições das empresas;
- Expandir o clustering com métodos hierárquicos (DBSCAN, agglomerative).

10 Referências

1. Crunchbase. *Startup Investments Dataset*. Disponível em: <https://www.kaggle.com/datasets/arindam235/startup-investments-crunchbase>
2. Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
3. Chawla, N.V. et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
4. Kimball, R. & Ross, M. (2013). *The Data Warehouse Toolkit*. 3rd ed. Wiley.
5. Zaharia, M. et al. (2016). Apache Spark: A Unified Engine for Big Data Processing. *Communications of the ACM*, 59(11), 56–65.
6. Microsoft. *Power BI Documentation*. Disponível em: <https://learn.microsoft.com/power-bi/>

7. Databricks. *Free Edition Documentation*. Disponível em: <https://docs.databricks.com/>

11 Acknowledgements

Claude (Anthropic) foi utilizado para assistir na da estrutura do código, pipeline ETL (Data Bricks) , queries OLAP e modelos de Machine Learning no Data Mining.